



INSTITUTO UNIVERSITARIO DEL AZUAY

Nombres:

Rubén Alexander Castro Vivanco

DOCENTE:

Daniel Ortiz

TEMA:

Proyecto: Pipeline de Datos Covid-19

Materia:

Análisis de datos en Python

Informe Proyecto: Pipeline de Datos COVID-19


1. Introducción

El presente informe describe el desarrollo de un **pipeline de datos automatizado** implementado con **Dagster** para el análisis de información relacionada con la pandemia de **COVID-19**. La fuente principal de datos es el dataset canónico de **Our World in Data (OWID)**.

El objetivo del proyecto es **automatizar todo el flujo de procesamiento de datos**: extracción, validación, limpieza, cálculo de métricas epidemiológicas y generación de reportes, centrándose en los países **Ecuador** y **Colombia**.

2. Arquitectura del Pipeline

El pipeline está diseñado bajo un esquema basado en **assets** de Dagster. Cada asset representa un paso independiente y reutilizable. La arquitectura general es la siguiente:



3. Descripción de los Assets

Asset	Descripción
leer_datos	Descarga el CSV desde OWID y normaliza columnas.
leer_datos_chequeos_entrada	Aplica validaciones iniciales: columnas clave, duplicados, nulos y fechas.
datos_procesados	Filtra países, elimina duplicados, limpia nulos y selecciona columnas esenciales.
metrica_incidencia_7d	Calcula la incidencia acumulada a 7 días por cada 100k habitantes.
metrica_factor_crec_7d	Calcula el factor de crecimiento semanal.
chequeos_salida_incidencia	Verifica que las métricas calculadas estén dentro de rangos razonables.
tabla_perfilado	Genera un perfilado automático con estadísticas básicas.
reporte_excel_covid	Exporta datos procesados y métricas a un archivo Excel final.

4. Validaciones Implementadas

4.1 Chequeos de Entrada

- Verificación de columnas obligatorias: location, date, new_cases.
- Fechas no futuras ($\max(\text{date}) \leq \text{hoy}$).
- Unicidad de claves (location + date).
- Eliminación de valores nulos críticos en new_cases y people_vaccinated.
- Población positiva ($\text{population} > 0$).
- Avisos si existen valores negativos en new_cases.

4.2 Chequeos de Salida

- Validación de rangos de la métrica incidencia_7d:
 $0 \leq \text{incidencia_7d} \leq 2000$.


5. Artefactos Generados

El pipeline produce automáticamente los siguientes archivos:

Archivo	Descripción
tabla_perfilado.csv	Perfilado básico con información de columnas, valores nulos, mínimos, máximos y rango de fechas.
reporte_covid.xlsx	Reporte final con datos procesados y dos hojas de métricas: incidencia acumulada y factor de crecimiento.

6. Resultados Obtenidos

- **Automatización total del pipeline:** desde la descarga de datos hasta la exportación de reportes.
- **Métricas epidemiológicas clave:**
 - Incidencia acumulada a 7 días / 100k habitantes.
 - Factor de crecimiento semanal.
- **Validaciones automáticas:**
 - Control de calidad en datos de entrada.
 - Validación de métricas calculadas.



7. Conclusión

El proyecto evidencia el potencial de Dagster para construir pipelines de datos reproducibles y confiables, ya que permite automatizar la extracción, validación y procesamiento de la información de COVID-19, garantizando la calidad de los resultados mediante chequeos de entrada y salida. La arquitectura basada en assets asegura trazabilidad y escalabilidad, mientras que la generación automática de métricas y reportes en Excel facilita su análisis posterior y ofrece una herramienta adaptable para la toma de decisiones clave.